

Guía de Orientación para Estudiantes

Evaluación Sumativa EA1: Análisis Exploratorio y Preprocesamiento de Datos

1. Resumen de indicadores

#	Que se evalua	Puntaje
IE 1	Estructura CRISP-DM visible en el notebook	10%
IE 2	Identificar variable objetivo para REGRESION	10%
IE 3	Identificar variable objetivo para CLASIFICACION	10%
IE 4	Uso correcto de librerias Python (numpy, sklearn, matplotlib, seaborn)	10%
IE 5	Limpieza y preparación de datos con Python	10%
IE 6	Documentación del proceso con comparaciones al negocio	10%
IE 7	Tratamiento de outliers y missing values	10%
IE 8	Estadísticos de tendencia central y dispersión	10%
IE 9	Normalización o estandarización según distribución de los datos	10%
IE 10	Markdown justificando cada decisión tomada	10%
TOTAL		100%

2. Información general de la entrega

Formato	Jupyter Notebook (.ipynb) o Google Colab
Lenguaje	Python 3
Equipos	Grupos de 2 a 3 estudiantes (NO se aceptan trabajos individuales)
Ponderación	70% de la nota parcial 1, que corresponde al 40% de la asignatura Se ajusta la nota de acuerdo al resultado de la defensa individual
Metodología	CRISP-DM: solo las Fases 1, 2 y 3
Dataset	Asignado por el profesor

3. Estructura mínima del notebook

Seccion	Contenido minimo esperado	Fase
1. Portada	Título, integrantes, dataset, fecha	-

GUIA DE ORIENTACIÓN - MLY0100 Machine Learning		Evaluación Parcial 1
2. Comprensión del negocio	Contexto, objetivo, pregunta analítica, supuestos	Fase 1
3. Carga de librerías y datos	import, read_csv, shape, head()	Fase 2
4. Inspección de estructura	dtypes, info(), describe(), tipos de variables	Fase 2
5. Estadísticos descriptivos	Media, mediana, moda, std, varianza, IQR	Fase 2
6. Distribuciones	Histogramas, boxplots, barras, scatter, heatmap	Fase 2
7. Missing values	Detección, mecanismo (MCAR/MAR/MNAR), tratamiento	Fase 2-3
8. Outliers	Detección con IQR y Z-score, visualización, tratamiento	Fase 2-3
9. Normalización / Estandarización	Aplicar según distribución de cada variable	Fase 3
10. Dataset final	Dataset limpio, forma final, exportar CSV	Fase 3
11. Conclusiones	Hallazgos, decisiones, próximos pasos (modelado)	Fase 3

4. Detalle por Indicador de Evaluación

IE 1	Usar las fases de CRISP-DM como estructura del notebook	10%
- El notebook debe tener secciones tituladas claramente en markdown: Fase 1 Comprensión del Negocio, Fase 2 Comprensión de los Datos, Fase 3 Preparación de los Datos. - Cada fase debe comenzar con un título de nivel 1 o 2 en markdown (# o ##). - El flujo del notebook debe seguir el orden de CRISP-DM, no ser una colección de celdas sin estructura.		
IE 2	Identificar la variable objetivo para REGRESION	10%
- Proponer en markdown una variable numérica continua como target para regresión (ej: precio, tiempo de entrega). - Justificar por qué esa variable es adecuada: es numérica continua y representa una cantidad que se quiere predecir. - No es necesario entrenar el modelo en esta entrega, solo identificarlo y justificarlo con texto.		
IE 3	Identificar la variable objetivo para CLASIFICACION	10%
- Proponer en markdown una variable categórica o binaria como target para clasificación (ej: si/no, nivel alto/bajo). - Justificar por qué esa variable es adecuada: toma valores discretos que representan clases. - Puede ser la misma variable de regresión transformada en categorías, o una variable diferente.		
IE 4	Usar librerías Python correctamente	10%
- Importar y usar al menos: numpy, pandas, matplotlib, seaborn, scipy.stats y sklearn (KNNImputer, scalers). - Cada librería debe usarse funcionalmente, no solo importarse sin usar en ningún lugar del notebook. - Todas las visualizaciones deben tener título, etiquetas en ambos ejes y ser legibles.		
IE 5	Realizar limpieza y preparación de datos	10%
Verificar y corregir tipos de datos (fechas como datetime, categóricas como category, etc.).		

- Aplicar al menos dos técnicas de limpieza: eliminación/imputación de nulos y tratamiento de outliers.
- El dataset final debe estar listo para modelado: sin nulos, sin outliers extremos, tipos correctos.
- Exportar el dataset limpio al final del notebook con `to_csv()`.

IE 6 Documentar el proceso comparando resultados con el negocio

10%

- Antes de cada bloque de código, incluir celda markdown que explique QUÉ se va a hacer y POR QUÉ.
- Después de cada análisis, agregar una celda markdown con hallazgos y su relación con el negocio.
- Comparar estadísticos con lo esperado del negocio: "la alta desviación estándar indica que..."
- Incluir una sección de conclusiones al final que responda la pregunta de negocio planteada en la Fase 1.

IE 7 Tratar outliers y missing values según la naturaleza de los datos

10%

- MISSING VALUES: identificar mecanismo (MCAR, MAR o MNAR). Elegir estrategia correcta: descarte si el porcentaje es bajo (<5%), imputación por mediana para numéricas, moda para categóricas, o KNNImputer.
- OUTLIERS: detectar con IQR y/o Z-score, visualizar con boxplot. Elegir entre eliminar filas o imputar con media/mediana según el impacto en el dataset.
- Justificar en markdown cada decisión: por qué ese método, cuantos datos se perdieron si se eliminaron.

IE 8 Integrar estadísticos de tendencia central y dispersión

10%

- Calcular para cada variable numérica relevante: media, mediana, moda, desviación estándar, varianza e IQR.
- Construir una tabla comparativa con todos los estadísticos juntos usando `describe()`.
- Incluir histogramas con media y mediana marcadas, y boxplots para visualizar dispersión y outliers.
- Relacionar los estadísticos con el negocio en celdas markdown.

IE 9 Proponer y aplicar normalización o estandarización

10%

- Analizar la distribución de cada variable numérica (simétrica, asimétrica, con outliers) para decidir la técnica.
- NORMALIZACION (MinMaxScaler): usar cuando la distribución NO es normal y se quieren valores entre 0 y 1. Adecuada para datos sin muchos outliers.
- ESTANDARIZACION (StandardScaler): usar cuando la distribución se aproxima a la normal. Mas robusta si hay outliers. Deja media=0 y std=1.
- Justificar en markdown que técnica se aplica a cada variable y por qué, basándose en la distribución observada.
- Mostrar comparación de estadísticos antes y después de la transformación.

IE 10 Documentar con markdown justificando cada técnica

10%

- Usar celdas markdown ANTES de cada bloque de código explicando que se hace y por qué se eligió esa técnica.
- Indicar supuestos al inicio y conclusiones al final de cada sección.
- El notebook debe poder leerse de arriba a abajo como un informe sin necesidad de ver el código.
- Usar formato markdown: títulos (#, ##), negrita (**texto**), tablas, listas (-) y citas (>) para resaltar decisiones.

5. Checklist de revision antes de entregar

#	Revisar que...	Listo?
IE 1	El notebook tiene secciones con las 3 fases de CRISP-DM en markdown	☐
IE 2	Se propone y justifica una variable objetivo para REGRESIÓN	☐
IE 3	Se propone y justifica una variable objetivo para CLASIFICACIÓN	☐
IE 4	Se usan numpy, pandas, scipy, matplotlib, seaborn y sklearn	☐
IE 5	Los datos están limpios: sin nulos, sin outliers extremos, tipos correctos	☐
IE 6	Cada sección tiene contexto de negocio y comparación de resultados	☐
IE 7	Se aplico tratamiento a nulos (mecanismo identificado) y a outliers	☐
IE 8	Se calcularon media, mediana, moda, std, varianza e IQR con visualizaciones	☐
IE 9	Se aplico MinMaxScaler o StandardScaler con justificación de la elección	☐
IE 10	Cada decisión está documentada en markdown antes y después del código	☐
Extra	El notebook se ejecuta de principio a fin sin errores	☐
Extra	Las conclusiones responden a la pregunta de negocio planteada en Fase 1	☐

RECUERDA	El profesor evalúa tanto el CODIGO como el RAZONAMIENTO expresado en markdown. Un notebook con código correcto, pero sin justificaciones no alcanza el nivel "Muy buen desempeño". Escribe como si el profesor no pudiera ver el código y debiera entender todo solo leyendo el markdown.
-----------------	---